

Porównanie algorytmów scieniania odciskow palcow

Kacper Król, Igor Starega

28 maja 2026

Spis treści

1	Cel i zakres	3
2	Instrukcja użytkownika	3
3	Struktura rozwiązania i technologie	4
4	Charakterystyka problemu	4
5	Pipeline przetwarzania	4
6	Model matematyczny i metody	5
6.1	Binaryzacja Otsu i Sauvola	5
6.2	Szkieletyzacja morfologiczna	5
6.3	K3M	5
6.4	KMM	6
6.5	Detekcja minucji	6
7	Parametry i ustawienia domyslnie	6
8	Kryteria porównania algorytmów	7
9	Wyniki dla obrazu igor/rsmall3	7
10	Porównanie algorytmów	7
10.1	Jakosc szkieletu	7
10.2	Minucje	8
11	Omowienie wynikow	8
12	Wizualizacje	8
13	Mozliwe kierunki rozwoju	11
14	Wnioski	12

1 Cel i zakres

Celem projektu było przygotowanie programu do porównania algorytmów ścieniania w odniesieniu do obrazów odcisków palców. Ścienianie jest jednym z kluczowych etapów przetwarzania odcisków palca, ponieważ pozwala przekształcić grube linie papilarne w ich jednopikselową reprezentację szkieletową. Dzięki temu możliwa jest późniejsza analiza struktury linii oraz wykrywanie charakterystycznych punktów, takich jak zakończenia i bifurkacje. Pipeline obejmuje wczytanie obrazu, poprawę kontrastu, binaryzację, czyszczenie morfologiczne, ścienianie, postprocessing oraz detekcję minucji.

Zrealizowane wymagania:

- implementacja trzech algorytmów ścieniania: szkieletyzacji morfologicznej, K3M oraz KMM,
- dodatkowe operacje poprawiające ciągłość linii papilarnych,
- lokalizacja minucji, czyli zakończeń i bifurkacji,
- przygotowanie wizualizacji kolejnych etapów przetwarzania,
- eksport wyników liczbowych,
- raport z porównaniem wyników i wizualizacjami.

2 Instrukcja użytkownika

Instalacja:

1. `pip install -r requirements.txt`

Uruchomienie aplikacji:

1. `python app.py`

Typowy sposób pracy z programem jest następujący:

1. uruchomienie aplikacji,
2. wczytanie obrazu odcisku palca,
3. wybór lub pozostawienie domyślnych parametrów przetwarzania,
4. uruchomienie pipeline'u,
5. porównanie wyników dla algorytmów morfologicznego, K3M oraz KMM,
6. eksport wyników do dalszej analizy.

3 Struktura rozwiązania i technologie

Najważniejsze pliki projektu:

- `fingerprint_processor.py` – pipeline przetwarzania, scienianie i minucje,
- `app.py` – GUI w `tkinter` z podglądem etapów oraz eksportem wyników,
- `requirements.txt` – zależności.

Technologie: Python 3.x, biblioteka Pillow do IO i renderingu oraz `tkinter` do interfejsu graficznego.

4 Charakterystyka problemu

Odcisk palca składa się z układu linii papilarnych, które tworzą charakterystyczny wzór. W systemach biometrycznych najczęściej nie porównuje się całych obrazów piksel po pikselu, lecz wyznacza się cechy lokalne. Do najważniejszych cech należą minucje, czyli punkty opisujące lokalną strukturę grzbietów. Najczęściej rozpatrywane są:

- zakończenia linii papilarnych,
- bifurkacje, czyli miejsca, w których jedna linia rozdziela się na dwie.

Aby możliwe było poprawne wykrycie tych punktów, obraz musi zostać odpowiednio przygotowany. Surowe obrazy odcisków palców mogą zawierać szum, nierównomierne oświetlenie, zabrudzenia, fragmenty tła, przerwy w liniach oraz lokalne spadki kontrastu. Takie zakłócenia mogą prowadzić do powstawania fałszywych minucji. Przykładowo niewielka przerwa w linii papilarnej może zostać zinterpretowana jako dwa zakończenia, mimo że w rzeczywistości dana linia powinna być ciągła. Z tego powodu etap scieniania jest ściśle powiązany z etapami wcześniejszymi i późniejszymi. Dobra binaryzacja ułatwia uzyskanie czystego szkieletu, a dobry postprocessing ogranicza liczbę artefaktów po scienianiu. W praktyce jakość końcowej detekcji minucji zależy więc od całego pipeline’u, a nie tylko od pojedynczego algorytmu.

5 Pipeline przetwarzania

Pipeline składa się z następujących kroków:

1. Wczytanie obrazu i wzmocnienie kontrastu (stretching percentylowy).
2. Binaryzacja: Otsu lub adaptacyjna Sauvola (tryb `auto`).
3. (Opcjonalnie) maska obszaru odcisku oparta o lokalne odchylenie standardowe.
4. Czyszczenie morfologiczne (domknięcie i otwarcie).
5. Scienianie: morfologiczne, K3M oraz KMM.
6. Postprocessing: łączenie przerw i usuwanie krótkich odnog.
7. Detekcja minucji metoda *crossing number*.

Pipeline składa się z różnych ale równieważnych etapów. Poprawa kontrastu zwiększa różnicę pomiędzy liniami papilarnymi a tłem. Binaryzacja sprowadza obraz do postaci czarno-białej, co jest wymagane przez algorytmy ścieniania. Operacje morfologiczne ograniczają drobne zakłócenia i poprawiają spójność obszarów. Dopiero po tych etapach wykonywane jest właściwe ścienianie. Równie ważne jest postprocessing. Jego zadaniem jest ograniczenie błędów, które pojawiają się po ścienianiu. Nawet dobrze działający algorytm może pozostawić krótkie odnogi albo przerwy w szkielecie, jeżeli obraz wejściowy jest zaszumiony lub ma nierówną jakość.

6 Model matematyczny i metody

6.1 Binaryzacja Otsu i Sauvola

W przypadku Sauvola wykorzystywany jest prog lokalny:

$$T(x, y) = m(x, y) \left(1 + k \left(\frac{s(x, y)}{R} - 1 \right) \right),$$

gdzie m to średnia lokalna, s to odchylenie standardowe, a R to zakres dynamiczny.

W praktyce Sauvola jest mniej wrażliwa na nierównomierne oświetlenie i lokalne spadki kontrastu. Otsu korzysta z progu globalnego, co bywa wystarczające dla czystych skanów, ale słabiej działa na obrazach z cieniem lub przysłoniętymi fragmentami.

6.2 Szkieletyzacja morfologiczna

Algorytm opiera się na iteracyjnym erodowaniu obrazu i zbieraniu reszty po otwarciu:

$$S = \bigcup_{k=0}^{\infty} (I_k \setminus (I_k \circ B)), \quad I_{k+1} = I_k \ominus B.$$

W tym zapisie I_k oznacza obraz po k -tej erozji, B jest elementem strukturalnym, $\ominus$ oznacza erozję, a $\circ$ oznacza otwarcie morfologiczne. Idea metody polega na stopniowym zmniejszaniu obiektów i zachowywaniu tych pikseli, które tworzą ich szkielet.

Wynikiem jest szkieletyzacja o zachowanej topologii, ale wrażliwa na szum i drobne ubytki. Bez dodatkowego postprocessingu pojawiają się oderwane odnogi i lokalne rozczepienia, co zwiększa liczbę wykrywanych zakonczonych.

6.3 K3M

K3M to algorytm sekwencyjny z wielofazowym usuwaniem pikseli konturowych. Decyzje o usunięciu pikseli podejmowane są na podstawie wag sąsiedztwa oraz tablic faz. Algorytm analizuje lokalne otoczenie piksela i usuwa go tylko wtedy, gdy spełnione są określone warunki.

Algorytm wykonuje serię faz, w których piksel jest usuwany tylko wtedy, gdy należy do odpowiedniej grupy i nie narusza spójności obiektu. Dzięki temu szkielety są cienkie i stabilne. K3M zwykle dobrze zachowuje topologię obiektu, czyli nie powinien rozrywać linii ani usuwać istotnych połączeń.

Wadą K3M jest większa złożoność w porównaniu z prostymi operacjami morfologicznymi. Algorytm wymaga wielu iteracji oraz sprawdzania tablic decyzyjnych. W praktyce jednak dla obrazów odcisków palców daje uporządkowane wyniki, które dobrze nadają się do dalszej detekcji minucji.

6.4 KMM

KMM jest algorytmem iteracyjnym, w którym usuwane są piksele spełniające warunki topologiczne i należące do tablicy wag usunięcia. Dodatkowo sprawdzana jest prostota punktu (simple point).

W praktyce KMM agresywniej usuwa piksele z konturu, ale kontrola prostoty punktu ogranicza rozrywanie grzbietów. W porównaniu do K3M często pozostawia nieco grubszy szkieletyzowany obraz, co widać w liczbie pikseli szkieletu.

6.5 Detekcja minucji

Minucje wykrywane są za pomocą crossing number:

$$CN = \frac{1}{2} \sum_{i=1}^8 |p_i - p_{i+1}|,$$

gdzie $CN = 1$ oznacza zakończenie, a $CN = 3$ bifurkacje. Dodatkowo stosowane jest filtrowanie po minimalnym dystansie między punktami.

Detekcja wykonywana jest na szkielecie po postprocessingu. W praktyce liczba minucji jest silnie zależna od jakości binaryzacji i poziomu szumu w szkielecie. Metoda crossing number jest prosta i szybka, ale silnie zależy od jakości szkieletu. Jeżeli szkielet zawiera przerwy, krótkie odnogi lub lokalne zgrubienia, metoda może wykrywać fałszywe minucje. Dlatego detekcja wykonywana jest dopiero po postprocessingu.

7 Parametry i ustawienia domyślne

W eksperymentach użyto ustawień domyślnych aplikacji:

- binaryzacja: auto (Otsu lub Sauvola),
- Sauvola: okno 21, $k = 0.2$, $R = 128$,
- maska odcisku: wyłączona,
- domknięcie/otwarcie: 1,
- łączenie przerw: 1 iteracja, `max gap`=7,
- pruning odnog: 1 iteracja, `max length`=4,
- minimalny dystans minucji: 6 px.

Parametry są dobrane tak, aby zachować kompromis między czułością detekcji minucji a stabilnością szkieletu. Przy większej liczbie iteracji postprocessingu liczba minucji spada, ale spada też szczegółowość grzbietów, co jest widoczne zwłaszcza na słabszej jakości skanach.

Dobór parametrów jest szczególnie istotny w przypadku odcisków palców, ponieważ nawet niewielka zmiana progu binaryzacji lub długości usuwanych odnóg może istotnie zmienić liczbę wykrytych zakończeń. Zbyt słaby postprocessing pozostawia artefakty, natomiast zbyt silny może usuwać rzeczywiste cechy biometryczne.

8 Kryteria porównania algorytmów

Algorytmy porównano zarówno ilościowo, jak i jakościowo. Wyniki ilościowe obejmują liczbę pikseli szkieletu, liczbę zakończeń oraz liczbę bifurkacji. Wyniki jakościowe oceniono na podstawie wizualizacji surowych szkieletów oraz nakładek z minucjami. Przyjęto następujące kryteria:

- liczba pikseli szkieletu – informuje, jak cienki lub rozbudowany jest wynikowy szkielet,
- liczba zakończeń – pozwala ocenić podatność algorytmu na generowanie końców linii,
- liczba bifurkacji – wskazuje, ile rozgałęzień zostało wykrytych,
- ciągłość linii – oceniana wizualnie na podstawie przerw w szkielecie,
- liczba artefaktów – krótkich odnóg, izolowanych fragmentów i nieciągłości,
- czytelność wyniku – łatwość interpretacji obrazu po ścienianiu.

9 Wyniki dla obrazu igor/rsmall3

Poniżej zestawiono wyniki dla obrazu `igor/rsmall3.bmp` z pakietu `demo`.

Tabela 1: Podsumowanie wyników dla `igor/rsmall3.bmp`.

Algorytm	Prog	Piksele szkieletu	Zakonczenia	Bifurkacje
Morfologia	141	5946	459	11
K3M	141	5417	361	8
KMM	141	10447	516	8

Wyniki ilościowe pokazują, że KMM generuje najwięcej pikseli szkieletu oraz najwięcej minucji typu zakończenie. K3M daje najcięższy szkielety (najmniej pikseli), co przekłada się na mniejszą liczbę wykrytych minucji. Szkieletyzacja morfologiczna jest pomiędzy tymi dwoma przypadkami, ale w praktyce część minucji pochodzi z lokalnych zakłóceń i przerw w binarce.

W przypadku obrazu `rsmall3.bmp` liczba bifurkacji jest podobna dla K3M i KMM, co sugeruje, że główne rozgałęzienia zostały zachowane, a różnice wynikają głównie z dodatkowych odnóg oraz zakończeń generowanych przez szum.

10 Porównanie algorytmów

10.1 Jakość szkieletu

- **Morfologia** – szybka i prosta, ale wrażliwa na ubytki w binarce; często generuje krótkie odnogi i punkty widoczne jako dodatkowe zakończenia.
- **K3M** – stabilna topologia i cienki szkieletyzowany obraz, kosztem kilku iteracji i większego czasu obliczeń; daje najmniejszą liczbę pikseli szkieletu.

- **KMM** – zachowuje strukturę grzbietów, ale pozostawia nieco grubszy szkieletyzowany obraz, co przekłada się na większą liczbę wykrytych zakończeń.

10.2 Minucje

Wizualizacje 5 i 6 pokazują, że:

- liczba zakończeń jest najbardziej wrażliwa na drobne przerwy w szkielecie,
- bifurkacje są bardziej stabilne i mniej zależne od drobnych zakłóceń,
- K3M i KMM zachowują podobny układ bifurkacji, ale różnią się liczebnością zakończeń,
- część wykrytych zakończeń może być artefaktem, a nie rzeczywistą cechą biometryczną.

W praktycznych systemach rozpoznawania odcisków palców sama detekcja minucji nie wystarcza. Konieczne jest jeszcze odrzucenie punktów fałszywych, na przykład znajdujących się zbyt blisko krawędzi odcisku, w obszarach niskiej jakości lub na krótkich, przypadkowych odnogach szkieletu. W projekcie zastosowano podstawowe filtrowanie po minimalnym dystansie, ale można je dalej rozbudowywać.

11 Omowienie wyników

W praktyce najważniejsza rola pipeline’u to dostarczenie czystego szkieletu. Dla badanej próbki kluczowe okazały się:

- adaptacyjna binaryzacja (Sauvola), która stabilizuje widoczność grzbietów,
- łączenie przerw po scienianiu, które redukuje sztuczne zakończenia,
- pruning odnog, który usuwa krótkie artefakty.

Na obrazie `rsmall13.bmp` K3M daje najbardziej uporządkowany szkielet, ale może usuwać część drobnej struktury. KMM zachowuje więcej szczegółów, co bywa korzystne dla analizy minucji, ale zwiększa liczbę punktów zakończeń. Morfologia pozostaje najbardziej wrażliwa na szum w obrazie i wymaga najsilniejszego postprocessingu.

Wyniki pokazują, że nie istnieje jeden algorytm najlepszy w każdym sensie. Jeżeli priorytetem jest uzyskanie cienkiego i uporządkowanego szkieletu, lepiej wypada K3M. Jeżeli ważniejsze jest zachowanie większej liczby szczegółów, KMM może być korzystniejszy, ale wymaga dodatkowego filtrowania. Metoda morfologiczna jest prosta i zrozumiała, jednak jej wyniki są bardziej zależne od jakości binaryzacji.

12 Wizualizacje

Poniższe obrazy zostały wygenerowane dla `igor/rsmall13.bmp`.



(a) Oryginalny obraz wejściowy.



(b) Wzmocnienie kontrastu.

Rysunek 1: Etapy wstępnego przetwarzania.



(a) Binaryzacja.



(b) Po czyszczeniu morfologicznym.


Rysunek 2: Binaryzacja i oczyszczanie obrazu.



(a) Szkielet morfologiczny (surowy).




(b) K3M (surowy).




(c) KMM (surowy).


Rysunek 3: Porównanie surowych szkieletów.



(a) Morfologia: wszystkie minucje.




(b) K3M: wszystkie minucje.



(c) KMM: wszystkie minucje.

Rysunek 4: Nakładki minucji dla trzech algorytmów.




(a) Morfologia: zakonczenia.

(b) K3M: zakonczenia.

(c) KMM: zakonczenia.

Rysunek 5: Porównanie minucji typu zakonczenie.



(a) Morfologia: bifurkacje.

(b) K3M: bifurkacje.

(c) KMM: bifurkacje.

Rysunek 6: Porównanie minucji typu bifurkacja.

13 Możliwe kierunki rozwoju

Projekt można rozbudować w kilku kierunkach. Pierwszym rozszerzeniem byłoby przeprowadzenie testów na większym zbiorze obrazów. Pozwoliłoby to sprawdzić, czy obserwacje uzyskane dla `rsmall13.bmp` powtarzają się także dla innych skanów. Drugim kierunkiem rozwoju jest dodanie bardziej zaawansowanego filtrowania fałszywych minucji. Można usuwać punkty znajdujące się zbyt blisko brzegu maski odcisku, punkty położone w obszarach niskiej jakości lub pary zakończeń, które najprawdopodobniej wynikają z jednej przerwy w linii. Trzecim rozszerzeniem byłoby porównanie czasu działania algorytmów. Można także rozważyć dodanie filtrów kierunkowych, które wzmacniałyby linie papilarne zgodnie z lokalnym kierunkiem grzbietów. Taki etap mógłby poprawić jakość obrazu jeszcze przed binaryzacją i ścienianiem.

14 Wnioski

Najważniejsze obserwacje:

- Adaptacyjna binaryzacja, szczególnie Sauvola lub tryb `auto`, daje stabilniejsze maski dla skanów o nierównym oświetleniu.
- K3M i KMM generują bardziej jednolite szkielety niż szkieletyzacja morfologiczna, szczególnie w obszarach o słabym kontraście.
- K3M dał najbardziej uporządkowany szkielet dla analizowanej próbki i najmniejszą liczbę zakończeń.
- KMM zachował najwięcej pikseli szkieletu, ale jednocześnie wygenerował największą liczbę zakończeń.
- Bifurkacje okazały się bardziej stabilne niż zakończenia, ponieważ są mniej podatne na pojedyncze przerwy i krótkie artefakty.
- Łączenie przerw i pruning odnóg są kluczowe, aby ograniczyć artefakty i fałszywe minucje.
- Końcowa jakość detekcji minucji zależy od całego pipeline'u, a nie tylko od wybranego algorytmu ścieniania.

Podsumowując, K3M można uznać za najbardziej zrównoważony algorytm dla badanego obrazu, ponieważ wygenerował cienki i czytelny szkielet oraz ograniczył liczbę potencjalnie fałszywych zakończeń. KMM lepiej zachowuje szczegóły, ale wymaga dokładniejszego filtrowania wyników. Szkieletyzacja morfologiczna jest prostą i użyteczną metodą porównawczą, jednak jej wyniki są bardziej podatne na jakość obrazu binarnego oraz obecność szumu.